Nome: Jeann da Rocha Silva
Disciplina: Modelagem Estatística
Professor: Luíz Max Fagundes de Carvalho

Trabalho: Sobredispersão em modelos de contagem

Introdução

O conjunto de dados utilizado nesta análise é denominado *RecreationDemand* e está disponível no pacote AER do ambiente R. Ele foi construído a partir de uma pesquisa realizada em 1980 com 2000 proprietários de barcos de lazer no estado do Texas, Estados Unidos.

A variável de interesse para este trabalho é **trips**, que representa o número de viagens recreativas realizadas por cada entrevistado durante o período de observação. Além disso, a base inclui outras 7 variáveis socioeconômicas e ambientais, que são:

- **quality:** classificação subjetiva da qualidade da instalação em uma escala de 1 a 5 e 0 para quem não visitou o lago.
- **ski:** fator. O indivíduo praticava esqui aquático no lago?
- **income:** renda anual do entrevistado (em 1000 U$);
- **userfee:** fator. O indivíduo pagou uma taxa anual de uso no Lago Somerville?
- **costC:** despesas ao visitar o Lago Conroe (em U$);
- **costS:** despesas ao visitar o Lago Somerville (em U$);
- **costH:** despesas ao visitar o Lago Houston (em U$).

No que se segue, trataremos a coluna **trips** por variável resposta e as demais por covariáveis.

Realizaremos uma análise exploratória para identificar as covariáveis de interesse, isto é, que aparentam melhor explicar a variável **trips** e, junto a isso, ajustar alguns modelos para o problema, um dos quais será Poisson, e analisar a sua eficácia na descrição dessa variável. Ao final, serão apresentados os resultados com base nas ideias aqui desenvolvidas.

Análise Exploratória

De início, vamos explorar a estrutura dos dados como segue

Tabela 1: Estatísticas Descritivas das Variáveis

variável	mín.	1º Q.	mediana	média	3º Q.	máx.
`trips`	0.00	0.00	0.00	2.244	2.00	88.00
`quality`	0.00	0.00	0.00	1.419	3.00	5.00
`income`	1.00	3.00	3.00	3.853	5.00	9.00
`costC`	4.34	28.24	41.19	55.42	69.67	493.77
`costS`	4.77	33.31	47.00	59.93	72.57	491.55
`costH`	5.70	28.96	42.38	55.99	68.56	491.05

variável binária	categoria	frequência
`ski`	não	417
	sim	242
`userfee`	não	646
	sim	13

Uma análise simples revela que a variável resposta apresenta um excesso de 0's, que ocorrem entre o mínimo e o o meio do segundo e terceiro quartis. Além disso, observa-se também a ocorrência de eventos raros devido a alta discrepância do terceiro quartil (2.00) para o valor máximo (88.00) com a média estando muito próxima do terceiro quartil.

Observa-se também na covariável **quality** uma estrutura similar a **trips** com relação ao excesso de 0's, que provavelmente estão em correlação com os valores nulos da variável resposta correspondente, já que quem não viajou atribui valor 0. No entanto, há dois casos de pessoas que atribuiram 0 ao valor de **quality**, mas viajaram como segue abaixo.

Tabela 2: Observações com `quality = 0` e `trips` $\neq$ `0`

ID	trips	quality	ski	income	userfee	costC	costS	costH
560	4	0	sim	7	não	118.86	113.40	111.74
631	15	0	sim	3	não	58.30	57.28	56.70

Não há uma interpretação clara para estes dois casos, mas podemos supor que eles são apenas dados omitidos na pesquisa provavelmente por ausência de resposta.

Quanto às demais covariáveis, não se observa, a partir do sumário estatístico, evidências claras de associação com a variável resposta.

Voltando à variável resposta, a fim de observar como ela se comporta, vamos analisar a sua distribuição marginal

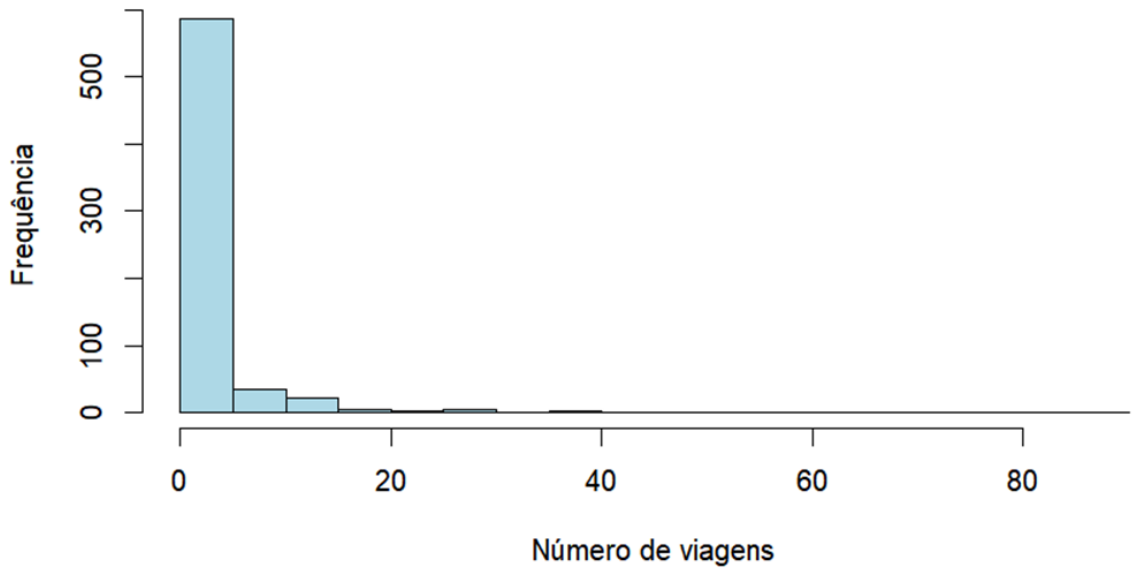


Figura 1: Distribuição do número de viagens

Tabela 3: Frequência dos valores da variável `trips`

trips	0	1	2	3	4	5	6	7	8	9	10	11	12	15	16	20	25	26	30	40	50	88
freq.	417	68	38	34	17	13	11	2	8	1	13	2	5	14	1	3	3	1	3	3	1	1

Como mencionado, temos um forte excesso de 0's (cerca de 63%) e a presença de eventos raros. Computando a média (já calculada anteriormente) e a variância, temos Não é segredo que

Tabela 4: Média e variância da variável `trips`

Estatística	**Valor**
Média	2.24431
Variância	39.59524

o alto valor da variância se deve justamente a este excesso de 0's. Entretanto, não se pode simplesmente excluí-los, já que eles representam informação relevante: "há pessoas que não viajam".

Agora passamos a uma questão relevante: "Todas as covariáveis são realmente importantes conjuntamente para inferir coisas sobre a variável **trips**?". Para responder isto, analisemos a matriz de covariância entre as covariáveis

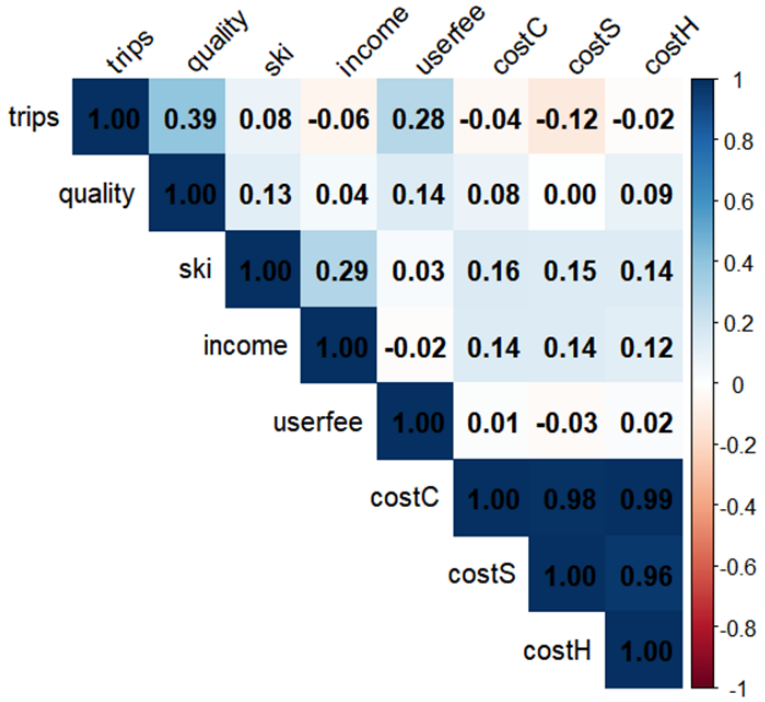


Figura 2: Matriz de covariância

De início, percebe-se que as covariáveis **costC**, **costS** e **costH** são altamente correlacionadas, o que implica que podemos considerar apenas uma delas para a regressão. Como estamos interessados no número de viagens ao lago Somerville, vamos considerar a covariável **costS**. Essa alta correlação se deve provavelmente ao fato de que os três lagos estão próximos geograficamente.

As demais covariáveis (incluindo as binárias) apresentam correlação relativamente baixa, mas agregam informações possivelmente relevantes e, por agora, manteremos nos modelos.

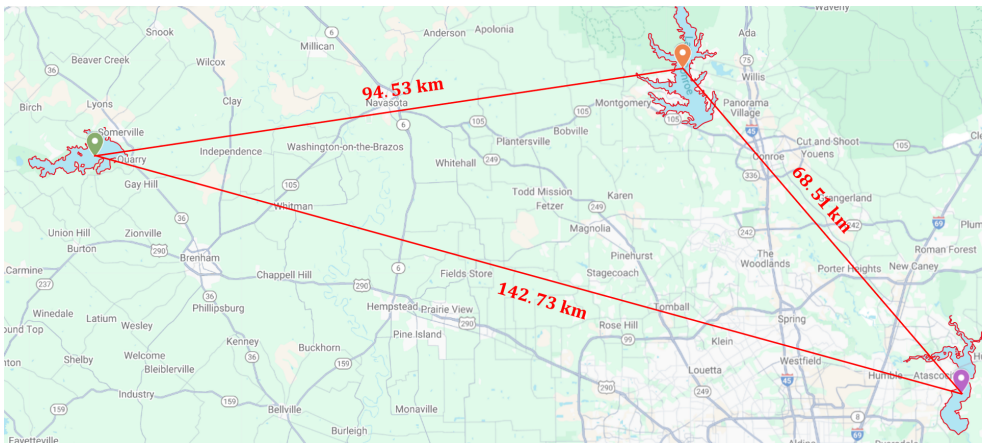


Figura 3: Distância aproximada entre os três lagos

Modelo Poisson

Vamos ajustar um modelo Poisson nos dados, uma vez que a variável **trips** representa uma contagem do número de viagens. O ajuste irá levar em conta o estimador de máxima verossimilhança dos parâmetros e utiliza o método de Fisher Scoring para estimar os parâmetros, que é o Newton-Raphson mas usa a informação esperada (ao invés da observada) para atualizar os coeficientes. Este é um método simples, rápido e de fácil interpretação dos coeficientes (na escala log), fornecendo estimativas pontuais (via máxima verossimilhança), erros padrões, p-valores e significância estatística.

Tabela 5: Resultados da Regressão Poisson

variável	**estimativa**	**erro padrão**	z **- valor**	p **- valor**	**significância**
Intercepto	0.5861	0.0919	6.38	1.80×10^{-10}	***
quality	0.5408	0.0159	33.92	$< 2 \times 10^{-16}$	***
income	-0.1578	0.0195	-8.09	5.82×10^{-16}	***
ski	0.4542	0.0565	8.04	8.69×10^{-16}	***
userfee	1.1015	0.0799	13.79	$< 2 \times 10^{-16}$	***
costS	-0.0153	0.0010	-15.10	$< 2 \times 10^{-16}$	***

Métricas do Modelo:

- Deviance nula: 4849.7 (df = 658)
- Deviance residual: 2687.5 (df = 653)
- AIC: 3452.6

Detalhes Adicionais:

- Parâmetro de dispersão (Poisson): 1 (Pressuposto do modelo)
- Significância (legenda): *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$
- Iterações de Fisher Scoring: 7

De forma ingênua, observamos pontos altamente positivos neste modelo: os p-valores associados

às estimativas dos coeficientes da regressão são muito pequenos, o que indica que eles são altamente significativos. Isso significa que a probabilidade de rejeitarmos a hipótese nula (de que o coeficiente seja zero) por acaso é extremamente baixa. Vemos que a deviance residual diminui substancialmente em relação a deviance nula, ou seja, a redução significativa da deviance sugere que o modelo com covariáveis é (muito) melhor do que o modelo nulo, que pressupõe que a variável resposta é constante. Por mais que os coeficientes estejam próximos de 0, o baixíssimo p-valor bem como o fato do intervalo gerado por até 3 desvios padrões não conter o 0, nos faz acreditar que este modelo seja muito bom em relação a qualquer outra versão que anula algum dos coeficientes.

Contudo, ao utilizarmos o modelo de Poisson, assumimos que a média e a variância da variável resposta são aproximadamente iguais. Isso se justifica pela propriedade fundamental da distribuição de Poisson: Se $Y \sim \text{Poisson}(\lambda)$, então $\mathbb{E}[Y] = \text{Var}(Y) = \lambda$. Se no nosso caso, a média amostral é relativamente próxima da variância amostral (e por relativo, queremos dizer que este valor não é discrepante em relação a escala das variáveis), então o modelo se aplica bem aos dados e, consequentemente, podemos inferir resultados relevantes a respeito da variável resposta e, através da deviance e do AIC, compará-lo com outros modelos. Agora, se não for esse o caso, então os pontos positivos acima destacados não agregam informação relevante (pois através de uma premissa falsa, podemos encontrar qualquer resultado, seja ele verdadeiro ou falso, bom ou ruim - "Ex Falso Quodlibet" -, e isto não é interessante).

A fim de verificar se ocorre **sobredispersão**, isto é, se o valor absoluto da diferença entre a média e a variância amostrais é consideravelmente alto, procedemos o seguinte teste de hipóteses, desenvolvido por Cameron e Trivedi em 1990. Sejam Y_i variáveis aleatórias que modelam os valores da variável resposta. Parametrizamos a variância como

$$\text{Var}(Y_i) = \mu_i + \alpha \cdot \mu_i^2$$

onde $\mu_i = \mathbb{E}[Y_i]$. Definimos as hipóteses nula e alternativa como

$$\begin{aligned} H_0 : &\quad \alpha = 0 \\ H_1 : &\quad \alpha \neq 0 \end{aligned}$$

É esperado, para um modelo Poisson, que

$$\text{Var}(Y_i) = \mu_i \Leftrightarrow \mathbb{E}[(Y_i - \mu_i)^2 - Y_i] = 0$$

O teste será disposto em três etapas

- Etapa 1: Obtemos os valores de média $\hat{\mu}_i$ ajustados no modelo Poisson considerado.
- Etapa 2: Computamos a estatística de teste

  $$Z_i = \frac{(Y_i - \mu_i)^2 - Y_i}{\hat{\mu}_i}$$

  Comentário: Segundo nossa parametrização, temos $Z_i = \alpha \cdot \mu_i$.
- Etapa 3: Regredimos Z_i em $\hat{\mu}_i$ sem intercepto e fazemos um teste-t no coeficiente da regressão.

O resultado da regressão foi:

- Coeficiente estimado: $\hat{\alpha} = 1.6406$

- Erro-padrão: 0.7664
- t-Valor: 2.141
- p-Valor: 0.0327

Como o p-Valor é inferior à 0.05, ou seja, tem nível de significância menor que 5%, rejeitamos a hipótese nula de ausência de sobredispersão. Portanto, há evidência estatística de que o modelo Poisson não é adequado, pois a variância observada nos dados é maior do que a assumida pelo modelo. O coeficiente estimado $\hat{\alpha} = 1.64 > 0$ reforça essa conclusão. Diante disso, vamos considerar outra abordagem.

Modelo Binomial Negativa

Vamos ajustar um modelo que segue uma distribuição Binomial Negativa nos dados, pois ele também representa uma contagem e pode ser derivado do seguinte modo: Vamos ainda considerar que o número de viagens segue uma distribuição Poisson(λ), mas para justificar a sobredispersão, consideramos que o número médio de viagens (isto é, o parâmetro da Poisson) λ não seja um valor fixo, mas sim uma variável aleatória e, consideramos uma distribuição a priori $\lambda \sim \text{Gama}(\alpha, \beta)$, com $\alpha, \beta > 0$, que pode ser uma boa escolha para refletir a variação na taxa. Assim, temos

$$Y_i|\lambda \sim \text{Poisson}(\lambda), \qquad \lambda \sim \text{Gama}(\alpha, \beta)$$

Logo, se π é a densidade de λ, a distribuição marginal de Y_i é portanto

$$\begin{aligned}
f_{Y_i}(y_i) &= \int_0^\infty f_{Y_i|\lambda}(y_i)\pi(\lambda)\, d\lambda \\
&= \int_0^\infty \frac{\lambda^{y_i}}{(y_i)!}e^{-\lambda}\frac{\beta^\alpha}{\Gamma(\alpha)}\lambda^{\alpha-1}e^{-\beta\lambda}\, d\lambda \\
&= \frac{\beta^\alpha}{\Gamma(\alpha)(y_i)!}\int_0^\infty \lambda^{\alpha+y_i-1}e^{-(\beta+1)\lambda}\, d\lambda \\
&= \frac{\Gamma(\alpha+y_i)\beta^\alpha}{\Gamma(\alpha)(y_i)!(\beta+1)^{\alpha+y_i}} \cdot \frac{(\beta+1)^{\alpha+y_i}}{\Gamma(\alpha+y_i)}\int_0^\infty \lambda^{\alpha+y_i-1}e^{-(\beta+1)\lambda}\, d\lambda \\
&= \frac{\Gamma(\alpha+y_i)\beta^\alpha}{\Gamma(\alpha)(y_i)!(\beta+1)^{\alpha+y_i}} \\
&= \frac{\Gamma(\alpha+y_i)}{(y_i)!\Gamma(\alpha)} \cdot \left(\frac{\beta}{\beta+1}\right)^\alpha \left(\frac{1}{\beta+1}\right)^{y_i}
\end{aligned}$$

Assim, $Y_i \sim \text{NegBin}\left(\alpha, \frac{\beta}{\beta+1}\right)$. Analisando sua média e variância, obtemos

$$\mathbb{E}[Y_i] = \frac{\alpha}{\beta} \qquad \text{Var}(Y_i) = \frac{\alpha}{\beta} + \frac{\alpha}{\beta^2} = \mathbb{E}[Y_i] + \frac{1}{\alpha}\mathbb{E}[Y_i]^2$$

Portanto, vamos considerar a parametrização da binomial negativa através de sua média $\mu = \frac{\alpha}{\beta}$ e dispersão $\theta = \alpha$. Neste caso, $Y_i \sim \text{NegBin}(\mu, \varphi)$ significa que $\mathbb{E}[Y_i] = \mu$ e $\text{Var}(Y_i) = \mu + \frac{\mu^2}{\theta}$.

O ajuste do modelo GLM Binomial Negativa terá, assim como o GLM Poisson, função de ligação log. Praticamente, os motivos desta escolha são os mesmo do modelo Poisson, dos quais podemos destacar o fato de que a média estimada $\hat{\mu}_i$ é positiva, o que faz sentido para um modelo de contagem. Além disso, para o modelo Poisson, a função de ligação log é bastante natural já que essa distribuição pertence a família exponencial canônica. Para a binomial negativa, que não está na família exponencial canônica, continua sendo útil em virtude da associação com a

distribuição de Poisson apresentada acima. Por fim, um pouco fora de contexto, para modelos de contagem, onde multiplicações são comuns, o uso da função log pode ser útil no que tange a otimização.

Segue abaixo o ajuste do modelo segundo um GLM Binomial Negativa

Tabela 6: Resultados da regressão Binomial Negativa

variável	**estimativa**	**erro padrão**	**z - valor**	**p - valor**	**significância**
Intercepto	-0.8369	0.2270	-3.69	0.000227	***
quality	0.8867	0.0422	21.00	$< 2 \times 10^{-16}$	***
income	-0.0663	0.0477	-1.40	0.164051	
ski	0.5533	0.1676	3.30	0.000959	***
userfee	1.5224	0.4255	3.58	0.000346	***
costS	-0.0126	0.0024	-5.18	2.2×10^{-7}	***

Métricas do Modelo:

- Deviance nula: 956.34 (df = 658)
- Deviance residual: 453.89 (df = 653)
- AIC: 1802.7

Detalhes Adicionais:

- Parâmetro de dispersão (Binomial Negativa): 0.4714, com erro padrão de 0.0448
- Significância (legenda): *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$
- Iterações de Fisher Scoring: 1

Observamos, com o resultado acima, que a deviance residual sofre uma redução significativa em relação a deviance nula e quase todas as covariáveis apresentam um baixo p-valor, com exceção da **income**. Também é clara a alta redução no AIC e na deviance em relação ao modelo de Poisson, mas isto não diz nada útil, uma vez que as premissas do modelo Poisson já não eram satisfeitas.

Vamos agora analisar a estrutura desse modelo para a adição e remoção de covariáveis. Mais precisamente, optaremos por certamente manter as covariáveis **quality** e **costS**, já que os p-valores destas refletem sua alta importância em relação as demais. Além disso, para as covariáveis binárias, consideramos a possibilidade de termos de interação. Inicialmente, vamos analisar a significância da covariável **income**. Removendo-a do GLM considerado, obtemos

- Deviance Nula: 947.51 (df = 658)
- Deviance Residual: 451.70 (df = 654)
- AIC: 1802.5
- Parâmetro de Dispersão: 0.4645, com erro padrão de 0.0438
- Iterações de Fisher Scoring: 1

Nota-se que todos as métricas continuam similares, mas com um leve declínio, o que significa que a covariável **income** não é estatisticamente significante para o modelo. A interpretação da covariável **income** não é clara, pois é possível encontrar informações da renda anual média familiar do texas no ano em questão que extrapolam o valor máximo da renda presente nos dados (em números, valores superiores a 50000 U$). Mas, se considerarmos ter algum sentido, talvez por um fator de reescala, pode-se observar que esse valor de renda supera a despesa média total de todas as viagens ao lago (basta calcular $\mathbf{income} \cdot 1000 - \mathbf{trips} \cdot \mathbf{costS}$ e notar que todas as coordenadas desse vetor são muito maiores que 0), ou seja, a renda é suficiente (e mais do que suficiente!) para que a pessoa possa viajar e, consequentemente, viajar se torna mais uma escolha individual do que algo que é afetado pela renda.

Removendo a covariável **income** do modelo, passamos a análise das covariáveis binárias **ski** e **userfee**. Alguns testes mostram que adicionar termos de interação não aparentam melhorar substancialmente o modelo (o AIC permanece aproximadamente inalterado). Além disso, a exclusão de ao menos uma dessas duas covariáveis resulta em um aumento de aproximadamente 20 unidades no AIC. Essa penalização substancial, aliada à ausência de justificativas teóricas ou empíricas para sua remoção, nos leva a mantê-las no modelo — mesmo considerando que a covariável **userfee** apresenta apenas 13 ocorrências positivas. Ficamos então com os seguintes resultados

Tabela 7: Resultados finais da regressão Binomial Negativa

variável	**estimativa**	**erro padrão**	**z - valor**	**p - valor**	**significância**
Intercepto	-1.0270	0.1736	-5.92	3.30×10^{-9}	***
quality	0.8937	0.0425	21.04	$< 2 \times 10^{-16}$	***
ski	0.5206	0.1625	3.20	0.001361	**
userfee	1.5221	0.4280	3.56	0.000377	***
costS	-0.0137	0.0025	-5.59	2.26×10^{-8}	***

Métricas do Modelo:

- Deviance nula: 947.51 (df = 658)
- Deviance residual: 451.70 (df = 654)
- AIC: 1802.5

Detalhes Adicionais:

- Parâmetro de dispersão (Binomial Negativa): 0.4645, com erro padrão de 0.0438
- Significância (legenda): *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$
- Iterações de Fisher Scoring: 1

Excesso de Zeros

Retornando a questão do excesso de zeros na variável resposta e ao modelo Poisson tratado anteriormente, podemos imaginar que a sobredispersão presente no modelo se deve ao excesso de zeros que atrai a média para um valor positivo menor e, consequentemente, mais distante da variância.

Para checar se isso de fato pode estar ocorrendo, podemos observar que há 417 zeros amostrados

na variável resposta. Mas, o modelo Poisson ajustado acima prevê cerca de 254 zeros. Isto é obtido mediante o seguinte raciocínio

$$\begin{aligned} \text{nº esperado de zeros previstos} &= E\left[\sum_{k=0}^{659} \mathbb{1}_{[Y_i=0]}\right] = \sum_{k=0}^{659} E[\mathbb{1}_{[Y_i=0]}] \\ &= \sum_{k=0}^{659} \mathbb{P}(Y_i = 0) = \sum_{k=0}^{659} e^{-\hat{\mu}_i} \approx 254 \end{aligned}$$

Isso indica que o modelo não está representando adequadamente a quantidade de zeros observada nos dados. Em consequência, esse pode ser um forte indicativo da sobredispersão.

Comentário: Calculando o número esperado de zeros previstos no modelo Binomial Negativa a fim de comparação, obtemos cerca de 422 zeros previstos, o que condiz com a realidade e revela a eficiência do modelo.

Para tratar esse problema, podemos considerar uma versão adaptada do modelo Poisson para este caso, que é o modelo Poisson Inflado de Zeros (ou Zero Inflated Poisson - ZIP). Este modelo consiste numa mistura de dois processos, um que representa a geração de zeros e outro que representa um processo de Poisson (que pode conter zeros). Formalmente, dizemos que Y tem distribuição inflada de zeros com parâmetros $\lambda > 0$ e $\pi \in (0, 1)$ — em notação: $Y \sim \text{ZeroInflPoisson}(\lambda, \pi)$ — se

$$\begin{aligned} P(Y = 0) &= \pi + (1 - \pi)e^{-\lambda} \\ P(Y = y) &= (1 - \pi)\frac{\lambda^y}{y!}e^{-\lambda}, \qquad y = 1, 2, 3, ... \end{aligned}$$

Podemos entender esta distribuição do seguinte modo: Seja $Z \sim \text{Poisson}(\lambda)$. Então, fazemos $Y = \pi\mathbb{1}_{[Y=0]} + (1 - \pi)Z$, ou seja, atribuímos uma proporção π de 0's inflacionados.

No modelo ZIP GLM, utilizamos as funções de ligação mais naturais de cada parte da distribuição. Assim, na parte de contagem, consideramos a função de ligação log

$$\log(\lambda_i) = x_i^T\beta \Leftrightarrow \lambda_i = e^{x_i^T\beta}$$

e na parte do número de zeros inflados, consideramos a função de ligação logit

$$\text{logit}(\pi_i) = z_i^T\beta \Leftrightarrow \pi_i = \frac{e^{z_i^T\beta}}{1 + e^{z_i^T\beta}}$$

onde x_i^T e z_i^T são vetores das covariáveis que explicam cada um dos parâmetros λ_i, π_i, respectivamente.

Pela correlação observada entre a covariável **quality** e a variável resposta, escolhemos como vetor de covariáveis z^T para π_i apenas os valores em **quality** (isto é, supomos que os zeros inflados estão diretamente relacionados com a qualidade da instalação, o que faz sentido, já que **quality** $= 0$ implica que provavelmente a pessoa não viajou). Além disso, o vetor de covariáveis x_i^T para as contagens será composto por todas as covariáveis consideradas até então (**quality**, **ski**, **userfee**, **costS**).

É importante observar que neste tipo de modelo os parâmetros da parte de contagem e da parte de inflação de zeros são ajustados simultaneamente via máxima verossimilhança, o que exige uma rotina de otimização numérica. Como a função de verossimilhança é mais complicada por envolver duas partes distintas, o método de Fisher Scoring não se aplica bem (já que este é um método para GLM mais simples, com derivadas mais comportadas). A verossimilhança

nesse caso não tem forma fechada simples para o sistema completo de equações score e, como resultado, não há uma matriz de informação esperada analítica fácil de obter, e o Fisher Scoring perde sua vantagem.

Por isso, o método utilizado será o BFGS (Broyden–Fletcher–Goldfarb–Shanno), que é um algoritmo quase-Newtoniano usado para maximização (ou minimização) de funções, como a log-verossimilhança no caso dos modelos estatísticos. É uma versão aprimorada do método de Newton, mas evita calcular diretamente a matriz Hessiana (segunda derivada), que pode ser cara ou instável.

Tabela 8: Resultados da regressão Zero-Inflated Poisson (ZIP)

Variáveis de contagem	**estimativa**	**erro padrão**	**z-valor**	**p-valor**	**significância**
(Intercepto)	2.1652	0.0885	24.46	$< 2 \times 10^{-16}$	***
quality	0.0410	0.0228	1.80	0.0719	.
ski	0.3937	0.0560	7.03	2.14×10^{-12}	***
userfee	0.8179	0.0785	10.42	$< 2 \times 10^{-16}$	***
costS	-0.0151	0.0010	-15.02	$< 2 \times 10^{-16}$	***

Variáveis de inflação de zeros	**estimativa**	**erro padrão**	**z-valor**	**p-valor**	**significância**
(Intercepto)	2.9662	0.2292	12.94	$< 2 \times 10^{-16}$	***
quality	-1.6112	0.1211	-13.30	$< 2 \times 10^{-16}$	***

Métricas do Modelo:

- AIC: 2586.016 (df = 7)
- Resíduos de Pearson: min = -3.5130, 1Q = -0.2493, mediana = -0.2060, 3Q = -0.1866, máx = 17.2976

Detalhes Adicionais:

- Significância (legenda): *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, . $p < 0.1$
- Número de iterações (BFGS): 14

Nota-se que a covariável **quality** perde muita significância na parte de contagem, o que pode indicar que ele seja um dado essencial apenas para refletir o número inflacionado de zeros. Ao retirá-la do vetor de covariáveis x_i^T, obtemos um modelo com AIC similar (como se observa abaixo), o que mostra que essa hipótese aparenta ser satisfeita.

Tabela 9: Resultados finais da regressão Zero-Inflated Poisson (ZIP)

Variáveis de contagem	**estimativa**	**erro padrão**	**z-valor**	**p-valor**	**significância**
(Intercepto)	2.2917	0.0529	43.29	$< 2 \times 10^{-16}$	***
ski	0.4081	0.0556	7.34	2.07×10^{-13}	***
userfee	0.8156	0.0785	10.39	$< 2 \times 10^{-16}$	***
costS	-0.0150	0.0010	-14.93	$< 2 \times 10^{-16}$	***

Variáveis de inflação de zeros	**estimativa**	**erro padrão**	**z-valor**	**p-valor**	**significância**
(Intercepto)	2.9895	0.2301	12.99	$< 2 \times 10^{-16}$	***
quality	-1.6285	0.1226	-13.28	$< 2 \times 10^{-16}$	***

Métricas do Modelo:

- AIC: 2587.276 (df = 6)
- Resíduos de Pearson: min = -3.3858, 1Q = -0.2708, mediana = -0.2058, 3Q = -0.1883, máx = 16.5646

Detalhes Adicionais:

- Significância (legenda): *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$
- Número de iterações (BFGS): 23

Comparando resultados

Reunindo as principais métricas de bondade do ajuste para cada modelo, temos

Tabela 10: Comparação entre modelos de regressão para contagem

modelo	**AIC**	**BIC**	**log-verossimilhança**	**deviance**
Poisson	3452.6	3479.5	-1720.9 (df = 6)	2687.5
Binomial Negativa	1802.5	1829.4	-895.2 (df = 6)	451.70
ZIP	2587.3	2614.2	-1287.6 (df = 6)	- -

Comentário: Calcular a deviance do modelo ZIP é algo complicado.

A Tabela acima resume o desempenho dos três modelos testados. O modelo Binomial Negativo destaca-se como ótimo candidato em todos os aspectos tratados:

- Menor AIC (1802.5) e BIC (1829.4), indicando melhor equilíbrio entre ajuste e complexidade;
- Deviance residual 83% menor que Poisson, refletindo melhor aderência aos dados;
- Log-Verossimilhança mais alta (-895.2), confirmando maior plausibilidade estatística.

O modelo ZIP, embora desenvolvido para excesso de zeros, mostrou-se inferior à Binomial Negativa em todas as métricas. Isso sugere que a parametrização da sobredispersão via distribuição

Gama-Poisson é suficiente para capturar a variabilidade dos dados, incluindo os zeros. Já o modelo Poisson falha criticalmente devido à subestimação da variância.

Os gráficos de dispersão dos valores preditos e seus respectivos resíduos também evidenciam que o modelo Binomial Negativa é uma melhor escolha dentre os três

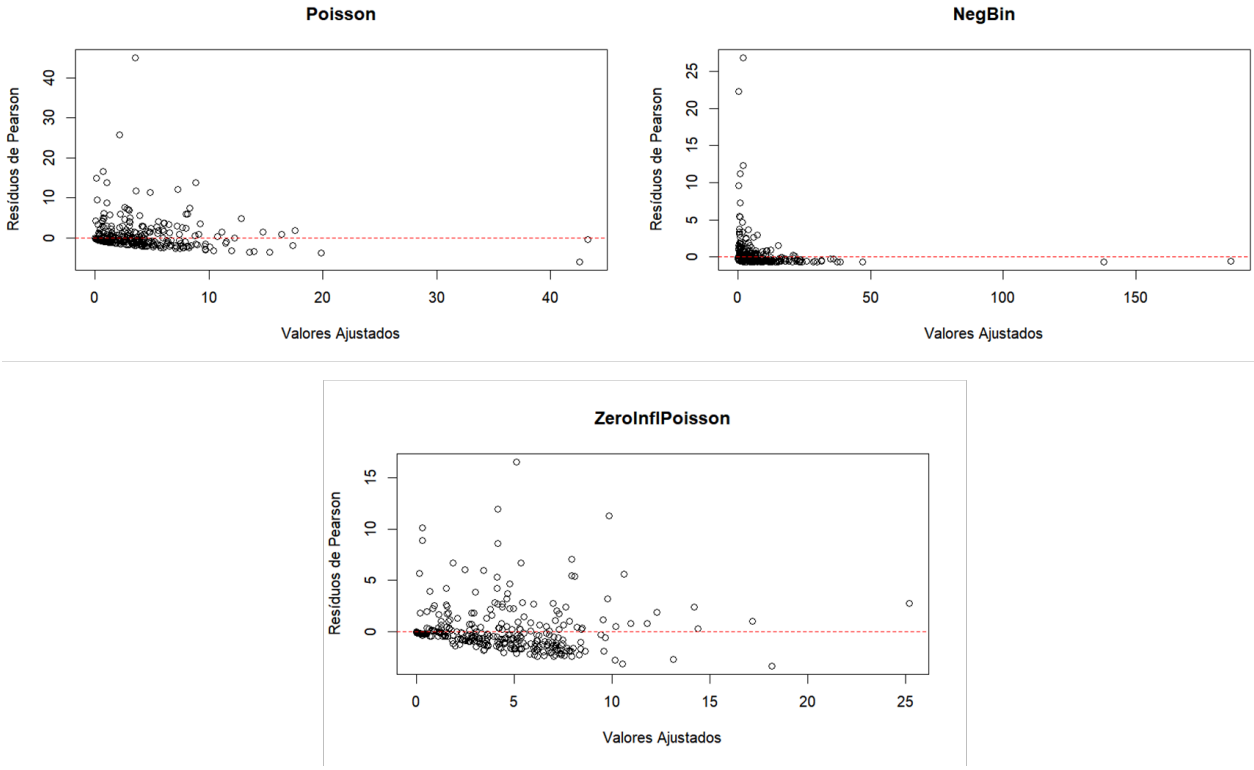


Figura 4: Resíduos vs Preditos

Como se vê, no modelo Poisson, Os resíduos estão altamente concentrados próximos de zero, mas existem vários pontos com resíduos muito altos, sugerindo a sobredispersão. Muitos resíduos afastados indicam que o modelo não está capturando bem a variabilidade dos dados. No modelo Binomial Negativa, os resíduos são visivelmente mais próximos do eixo das abscissas, mesmo para valores ajustados maiores. Há menos outliers e os resíduos têm distribuição mais homogênea, o que indica um ajuste melhor. Por fim, no modelo Poisson Inflado de Zeros, os resíduos também foram reduzidos em relação ao modelo de Poisson simples, o que indica melhoria. Contudo, ainda existem vários pontos com resíduos moderados a altos. Isso sugere que o modelo melhora o ajuste, especialmente para o excesso de zeros, mas não lida tão bem com a sobredispersão geral quanto o da Binomial Negativa.

Considerações finais

A análise mostrou que a Binomial Negativa foi o modelo mais adequado para descrever **trips**, controlando a sobredispersão dos dados e obtendo o melhor ajuste (AIC = 1802.5). As covariáveis **quality** (qualidade do lago) e **costS** (custo para visitar Somerville) se mostraram as mais relevantes, com impactos positivo e negativo respectivamente. Entretanto, ressaltamos que:

- Os resultados refletem padrões de 1980 e podem não capturar dinâmicas atuais (como mudanças ambientais ou no comportamento turístico);
- O excesso de zeros (63% dos dados) limita a precisão para prever o comportamento de quem viaja;

- A variável **userfee**, embora significativa, tem apenas 13 observações positivas, tornando suas estimativas sensíveis a outliers e exigindo validação externa;
- A variável **income** (renda) foi excluída do modelo final por não mostrar poder explicativo, sugerindo que viagens são mais influenciadas por fatores logísticos (custo, qualidade) do que socioeconômicos.

Apesar das limitações, o modelo oferece insights valiosos para políticas de gestão de parques tais como melhorar a infraestrutura (**quality**) e reduzir custos de acesso (**costS**) ao invés de subsídios diretos para aumentar visitas.

Referências

[1] KLEIBER, C.; ZEILEIS, A. Package Vignette and Errata. [s.l: s.n.].

[2] Cameron, A. C. and Trivedi, P. K. (1990). Regression-based tests for overdispersion in the Poisson model. Journal of econometrics, 46(3):347–364.

[3] GUNDERSEN, G. A Poisson–Gamma Mixture Is Negative-Binomially Distributed. 16 set. 2019.

[4] GONÇALVES DA SILVA, J.; HORIZONTE, B. Zero-Inflated Mixed Poisson Regression Models. [s.l: s.n.].

[5] CHEN, Y.-C.; HASTIE, T.; TIBSHIRANI, R. Lecture 7: Model Selection and Prediction. [s.l: s.n.].