Fundação Getúlio Vargas
Escola de Matemática Aplicada
Álgebra Linear

Clusterização de Textos

Alunos:
- Jeann da Rocha Silva
- Saulo Pires Vieira

Professor:
- Yuri Fahham Saporito

Novembro
2023

1 Abstract

In this project, we explore the application of the Natural Language Processing (NLP) techniques to classify texts into themes, even when the categories are not predefined. With knowledge of the categories in a dataset, we employ approaches to group texts into clusters based on textual similarities. The goal is to automatically identify underlying themes in texts and evaluate the effectiveness of this approach.

2 Introdução

O processamento de linguagem natural (PLN) desempenha um papel essencial na análise de texto e na compreensão da linguagem humana. Muitas vezes, a classificação de textos em temas é uma tarefa fundamental para organizar e entender grandes volumes de informações. Neste projeto, temos conhecimento de cinco categorias de textos: "business", "entertainment", "politics", "sport"e "tech".

Enfrentamos o desafio de classificar textos em temas sem categorias predefinidas, apesar de conhecermos as categorias mencionadas. Isso é particularmente relevante em cenários onde os textos não vêm com rótulos de categoria explícitos ou onde a atribuição de rótulos é uma tarefa complexa.

O objetivo principal deste projeto é aplicar algoritmos de agrupamento em textos não categorizados e identificar os temas ou tópicos subjacentes, com base nas categorias conhecidas. Para fazer isso, descrevemos a metodologia usada para pré-processar os textos, extrair características relevantes e aplicar técnicas de agrupamento para formar clusters de textos relacionados. A avaliação dos resultados é fundamental para determinar a eficácia dessa abordagem e seu potencial para identificar tópicos em textos não categorizados.

A seção seguinte apresentará em detalhes a metodologia usada para realizar essa tarefa de classificação não supervisionada de textos, levando em consideração as categorias. Em seguida, discutiremos os resultados obtidos e as conclusões decorrentes desse experimento.

3 Metodologia

Neste projeto, propomos uma abordagem para classificar textos em cinco temas principais: "business", "entertainment", "politics", "sport"e "tech". A metodologia inclui as seguintes etapas:

1. Coleta de Dados: Coletamos um conjunto de dados contendo textos relacionados aos cinco temas.

2. Pré-processamento de Texto: Realizamos o pré-processamento dos textos, incluindo a tokenização, etapas de limpeza (remoção de números e pontuações, conversão para minuscúlas, stemização e remoção de stopwords) e rotulação de POS.

3. Representação Vetorial: Representamos os textos como vetores, onde cada dimensão representa a contagem de palavras em um vocabulário específico.

4. Redução da Dimensionalidade: Utilizamos técnicas de Álgebra Linear (SVD) para reduzir a dimensão dos vetores que representam os textos para um plano k-dimensional (isto é, k coordenadas) que bem aproximasse os dados e apresentasse uma visualização simplificada e útil dos clusters (agrupamentos) que se mostrassem evidentes.

5. Aplicação de Medidas de Similaridade: Aplicamos duas medidas que representam numericamente o quão similares entre si as palavras e os textos se distribuiam. Por palavras, utilizamos a Distância de Levenshtein e, por textos (que é o caso), a Similaridade do Cosseno para duas abordagens distintas de distribuição de frequências (Count Vectorizer e TF-IDF).

Esta metodologia oferece uma abordagem simples para a classificação de textos em temas predefinidos, sem a necessidade de categorias adicionais. Os passos são projetados para serem eficazes e eficientes na atribuição de temas aos textos.

4 Desenvolvimento

4.1 Técnicas de Pré-Processamento

Ao lidar com textos, é essencial realizar uma série de etapas de pré-processamento para tornar os dados mais limpos e padronizados. A primeira decisão importante é como tokenizar os textos, ou seja, dividir o texto em unidades menores. Optamos por tokenizar por palavras, o que nos permite uma representação mais eficaz dos textos. Entretanto, poderiamos tokenizar também através de sentenças (frases), n-gramas ou outras formas determinadas por expressões regulares.

A tokenização por palavras é benéfica por diversas razões. Ela simplifica a representação textual, tornando o texto mais estruturado. Além disso, facilita a remoção de stopwords, que são palavras comuns, como “the”, “and”, “is”, “in”, “it”, “of”, “to”ou “for”, que geralmente não contribuem significativamente. Também permite que mantenhamos o significado semântico do texto, pois as palavras são unidades de significado na linguagem.

Um passo importante é a remoção de stopwords e números. As stopwords, como mencionado, são palavras comuns que não agregam valor semântico ao texto (em geral, preposições, artigos, interjeições, ...) e números geralmente não contribuem significativamente para o contexto. Por exemplo, considerando os textos:

1. Pedro foi à praia no dia 10.

2. Só pudemos ir à praia depois das 16 horas.

Ambos os textos são semanticamente semelhantes, mas os números não alteram o contexto. Portanto, a remoção de stopwords e números otimiza o processamento e a compreensão.

Outra etapa crucial é o processo de stemming ou radicalização das palavras. Isso envolve reduzir as palavras à sua forma básica ou radical. A razão para isso é que, ao analisar a proximidade entre textos, não é necessário considerar o tempo verbal ou a pessoa. Concentramo-nos apenas no radical de cada palavra para simplificar a análise e manter o foco nas semelhanças entre os textos.

Além disso, transformamos todo o texto em letras minúsculas (lowercase) e removemos as pontuações. Isso ajuda a padronizar o texto e evita que diferenças de capitalização ou travas de fala afetem a análise.

Por fim, no contexto em questão não foi fortemente utilizado, mas vale ressaltar uma outra etapa importante do processo de pré-processamento de textos, que é a rotulação de POS (Parts of Speech), que rotula cada termo de acordo com seu aspecto gramatical (Substantivo, Verbo, Adjetivo, ...).

Com todas essas etapas de pré-processamento, nossos textos estão prontos para análise e comparação de temas.

4.2 Vetorização

Faremos a representação vetorial usando o método de Contagem de Palavras (também chamado de Count Vectorizer ou Bag of Words), onde basicamente criamos um vetor para cada texto, onde cada coordenada representa uma palavra do conjunto de textos e o valor dessa coordenada será a frequência com que a palavra correspondente se repete no decorrer do texto. Assim, para cada texto, temos um vetor de fácil leitura e interpretação. Esse método é eficiente quando trabalhamos com bases de dados grandes, pois deixamos de lado características como a ordem das palavras. Isso seria importante caso fossemos trabalhar com analise de sentimos ou algo relacionado.

4.3 Redução da Dimensionalidade

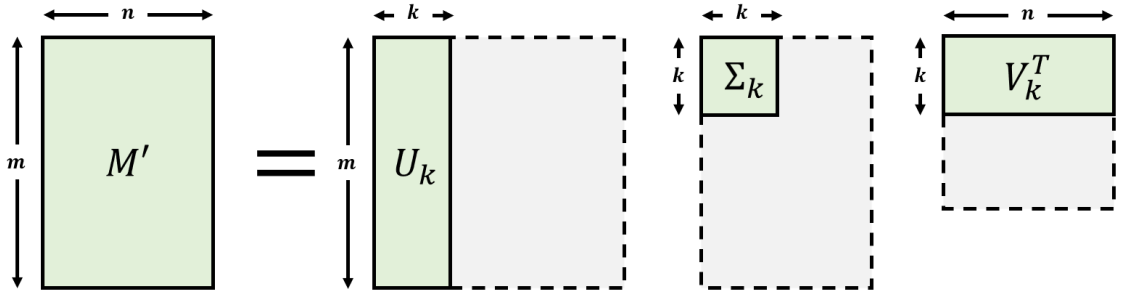
Com a vetorização empregada, formam-se espaços vazios (ou latentes) no espaço euclidiano que contém os vetores que representam os textos. A fim de analisar tais espaços latentes e, com isso, observar o agrupamento (cluster) formado pelos textos que são similares, empregamos a Decomposição em Valores Singulares (em inglês, Singular Value Decomposition ou SVD) para reduzir a dimensão dos vetores para um plano k-dimensional que aproxime bem os dados (isto é, um subespaço vetorial de dimensão k - ou $\mathbb{R}^k$ - cuja projeção dos dados preserva os espaços latentes entre os textos).

A Decomposição permite escrever a matriz $M_{m\times n}$ dos m vetores (obtidos pelo TF-IDF) como um produto de três matrizes

$$M_{m\times n} = U_{m\times m}\Sigma_{m\times n}V^T_{n\times n}$$

onde U é uma matriz cujas colunas são os autovetores de MM^T e V é uma matriz cujas linhas são os autovetores de M^TM. Além disso, Σ é uma matriz diagonal contendo a raiz quadrada dos autovalores de M^TM (valores Singulares).

A ideia é que se retirarmos k autovetores de U, k autovalores de V^T e k valores singulares de Σ que contribuem de maneira pequena para a construção da matriz M, então estaremos obtendo uma matriz M', que é aproximadamente a matriz M, com a vantagem de que efetuamos uma redução da dimensão dos vetores de M sem prejudicar de forma substancial os nossos dados, segundo o esquema abaixo



Claro que devemos tomar o devido cuidado com a quantidade de autovetores e valores singulares que eliminamos para manter uma boa aproximação. Felizmente, com técnicas de aprendizado de máquina conseguimos encontrar os melhores autovetores e valores singulares para a redução da dimensão de n para k.

As linhas de U_k serão a nova representação vetorial dos textos, que agora terão dimensão k e as linhas de V_k^T serão a representação vetorial dos k tópicos que definem os eixos do plano k-dimensional. Esses k tópicos serão vetores cujas coordenadas definem a proporção da respectiva palavra para a construção dos eixos.

4.4 Medidas de Similaridade

Utilizamos métricas que medem a semelhança léxica ou semântica entre nossos textos. Usamos a Distância de Levistein para medir a proximidade entre as palavras. Essa técnica conta quantas operações são necessárias para modificar uma palavra e obter a outra, sendo as operações permitidas: deletar um carácter, inserir um carácter e trocar dois caracteres de posição.

Também usamos a Similaridade do Cosseno entre dois textos específicos. Como nossos vetores tem o mesmo tamanho, podemos descrever a medida entre eles por

$$\text{similaridade} = cos(\theta) = \frac{A \cdot B}{||A||||B||}$$

que faz sentido geometricamente.

Porém, o metodo de Contagem de Palavras leva em consideração apenas a frequência com que cada palavra aparece e não sua importância relativa (palavras menos frequentes tendem a desenpenhar um papel maior para dar significado a um texto do que palavras mais frequentes). Para resolver tal problema vamos utilizar o TF-IDF (Term Frequency-Inverse Document Frequency), que leva em conta não só a frequência das palavras, mas também

sua importância na diferenciação dos textos. Podemos encontrar o índice TF-IDF de uma palavra em um texto da seguinte maneira:

$$\text{TF-IDF} = \text{TF} \cdot \text{IDF}$$

onde:

$$\text{TF} = \frac{\text{Numero de vezes que a palavra aparece no documento}}{\text{Número total de termos no documento}}$$

$$\text{IDF} = \log\left(\frac{\text{Número total de documentos na base de dados } + 1}{\text{Número de documentos que contêm a palavra} + 1}\right)$$

Se uma palavra aparace muitas vezes em um documento especifico, então essa palavra terá grande importância, essa é a função do TF, já o IDF é responsável por diminuir a importância da palavra caso ela apareça em muito textos, pois, apesar de termos retirado as stopwords, ainda existem palavras muito comuns, e precisamos dar mais importância a palavras mais raras.

Assim podemos aplicar o TF-IDF em cada palavra e assim otimizar nossa vetorização, não levando em conta apenas a frequência das palavras, pois agora com TD-IDF podemos atribuir pesos mais relevantes levando em consideração a raridade de cada palavra. Após isso, podemos aplicar o método da Similaridade do Cosseno de maneira mais precisa.

Vale ressaltar que a redução da dimensão deve ser feita previamente, a fim de otimizar todo o processo (menos coordenadas = menos tempo de execução) e tornar a similaridade mais precisa (sem a redução, haveriam muitas coordenadas com valor 0).

5 Resultados

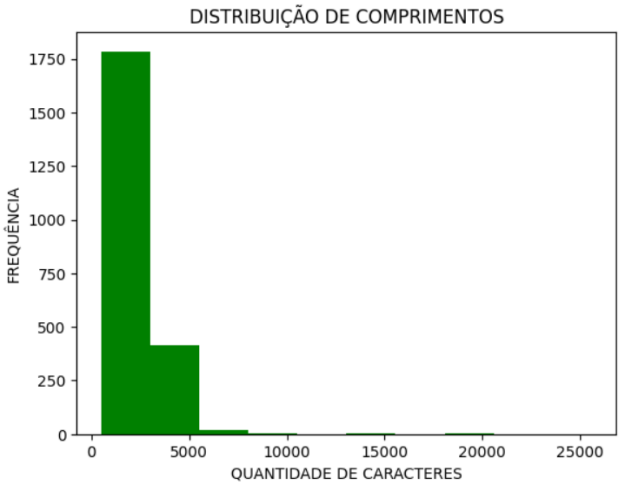
5.1 Abrindo a Base de Textos

A base de textos utilizada consiste de 2225 documentos do website da BBC news, correspondendo à histórias em cinco áreas temáticas de 2004-2005 e foi retirada de um site de base de dados diversos, cujo link está anexado nas referências [1]. Ela consta de cinco categorias de textos: "business", "entertainment", "politics", "sport"e "tech". Os documentos estavam dispostos, cada um, em blocos de notas, dentro de pastas com o respectivo nome da categoria, mas fizemos a conversão para um dataset com as mesmas informações.

Uma breve vizualização do dataset em sua forma inicial está apresentada abaixo

	label	texto
0	business	Ad sales boost Time Warner profit\n \n Quarte...
1	business	Dollar gains on Greenspan speech\n \n The dol...
2	business	Yukos unit buyer faces loan claim\n \n The ow...
3	business	High fuel prices hit BA's profits\n \n Britis...
4	business	Pernod takeover talk lifts Domecq\n \n Shares...
...	...	...
2220	tech	BT program to beat dialler scams\n \n BT is i...
2221	tech	Spam e-mails tempt net shoppers\n \n Computer...
2222	tech	Be careful how you code\n \n A new European d...
2223	tech	US cyber security chief resigns\n \n The man ...
2224	tech	Losing yourself in online gaming\n \n Online ...

2225 rows × 2 columns



O objetivo é trabalhar sobre os textos, segundo a metodologia apresentada e comparar os resultados de classificação obtidos com as categorias já pré-estabelecidas a fim de ver a acurácia da comparação.

5.2 Pré-Processando e Vetorizando os Textos

Após aplicarmos os passos de pré-processamento na base de dados, ela assume a seguinte aparência

	label	Quantidade de Caracteres	texto pré-processado	tokens	vectors	rotulacao
0	business	2571	ad sal boost tim warn profit quart profit us m...	[ad, sal, boost, tim, warn, profit, quart, pro...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(ad, NN), (sales, NNS), (boost, VBP), (time, ...
1	business	2259	dol gain greensp speech dol hit highest level ...	[doll, gain, greensp, speech, doll, hit, highe...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(dollar, NN), (gains, NNS), (greenspan, VBP),...
2	business	1559	yuko unit buy fac loan claim own embattl russ ...	[yuko, unit, buy, fac, loan, claim, own, embat...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(yukos, NNS), (unit, NN), (buyer, NN), (faces...
3	business	2423	high fuel pric hit bas profit brit airway blam...	[high, fuel, pric, hit, bas, profit, brit, air...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(high, JJ), (fuel, NN), (prices, NNS), (hit, ...
4	business	1577	pernod takeov talk lift domecq shar uk drink f...	[pernod, takeov, talk, lift, domecq, shar, uk,...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(pernod, NN), (takeover, NN), (talk, NN), (li...
...	...	...	...	...	...	...
2220	tech	2528	bt program beat dial scam bt introduc two in h...	[bt, program, beat, dial, scam, bt, introduc, ...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(bt, NN), (program, NN), (beat, NN), (dialler...
2221	tech	2296	spam email tempt net shop comput us across wor...	[spam, email, tempt, net, shop, comput, us, ac...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, ...	[(spam, NN), (emails, VBZ), (tempt, JJ), (net,...
2222	tech	6299	car cod new europ direct could put softw writ ...	[car, cod, new, europ, direct, could, put, sof...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, ...	[(careful, JJ), (code, NN), (new, JJ), (europe...
2223	tech	2325	us cyb sec chief resign man mak sur us comput ...	[us, cyb, sec, chief, resign, man, mak, sur, u...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(us, PRP), (cyber, VBP), (security, NN), (chi...
2224	tech	16250	los onlin gam onlin rol play gam timecons enth...	[los, onlin, gam, onlin, rol, play, gam, timec...	[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ...	[(losing, VBG), (online, NN), (gaming, VBG), (...

2225 rows × 6 columns

Observe que as palavras dos textos pré-processados apresentam relação com a categoria (coluna **label**). Por exemplo, nas primeiras linhas, vemos os termos *sal* (sales), *dol* (dollar),

gain (gain), *buy* (buy), *loan* (loan) e *prices* (pric), que possuem relação com a categoria *business* e, nas últimas linhas, vemos os termos *program* (program), *scam* (scam), *spam* (spam), *email* (email), *cod* (code), *cyb* (cyber), *onlin* (online) e *gam* (game), que possuem relação com a categoria *tech*.

Note que temos ambas as vetorizações (coluna **count vectorizer** e coluna **tfidf**), mas, como mencionado anteriormente, utilizaremos apenas os vetores em *TF-IDF*, em virtude da importância que uma palavra pode desempenhar num texto.

5.3 Reduzindo a Dimensão e Vizualizando os Textos

Aplicando a redução da dimensão dos vetores para 5 tópicos (5 coordenadas), obtemos os seguintes resultados

	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
Document 0	0.1648	0.1270	0.3097	0.1806	0.1397
Document 1	0.2355	0.2516	0.4276	0.1913	0.0703
Document 2	0.1415	0.1590	0.2263	0.1260	0.0963
Document 3	0.1803	0.1657	0.3312	0.1569	0.0890
Document 4	0.0854	0.0702	0.1218	0.0735	0.0664
...	...	...	...	...	...
Document 2220	0.1719	0.1310	0.2719	0.2019	0.2861
Document 2221	0.1655	0.1324	0.2632	0.1919	0.3101
Document 2222	0.2337	0.2290	0.2736	0.2670	0.3290
Document 2223	0.1393	0.1596	0.1684	0.1549	0.2083
Document 2224	0.3072	0.0867	0.2163	0.1677	0.4313

2225 rows × 5 columns

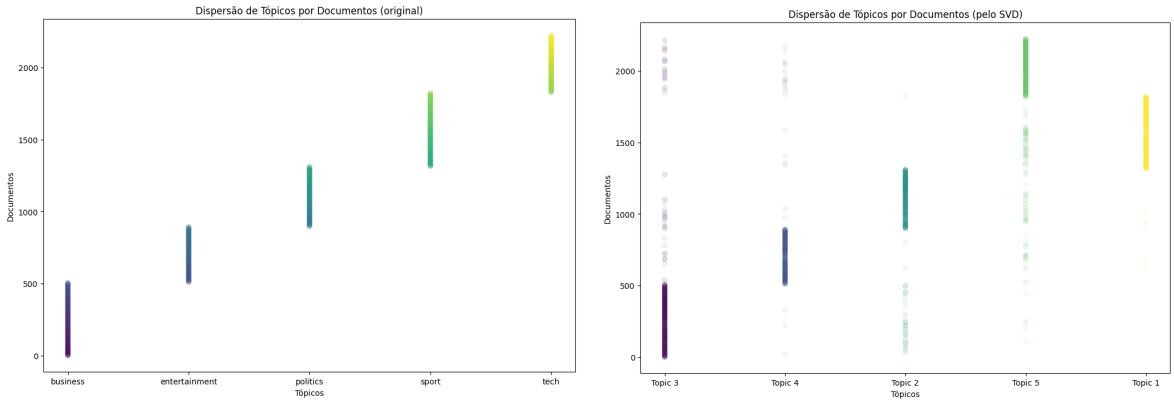
onde cada tópico tem uma representação vetorial por n (o número de colunas da matriz original) coordenadas, indicando quais palavras atuam para a formação de cada tópico. Para os tópicos gerados, os 10 termos (tokens) que melhor representam eles são

```
1º Tópico: ['said', 'mr', 'year', 'econom', 'gam', 'play', 'peopl', 'new', 'elect', 'labo']
2º Tópico: ['mr', 'labo', 'elect', 'blair', 'party', 'tax', 'tory', 'brown', 'govern', 'lib']
3º Tópico: ['econom', 'grow', 'rat', 'bank', 'market', 'pric', 'consum', 'mobl', 'sal', 'ris']
4º Tópico: ['film', 'award', 'best', 'nomin', 'osc', 'mus', 'star', 'direct', 'actress', 'fest']
5º Tópico: ['mobl', 'phon', 'technolog', 'peopl', 'gam', 'digit', 'mus', 'serv', 'dev', 'softw']
```

Observe que no 5º tópico, os termos "mobl" (mobile), "phon" (phone), "technolog" (technolog), "gam" (game), "digit" (digital), "serv" (server), "dev" (developer) e "softw" (software) já indicam se tratar de tecnologia (*tech*). Do mesmo modo, no 4º tópico, os termos indicam se tratar de entretenimento (*entertainment*), no 3º tópico, negócios

(*business*), no 2º, política (*politcs*) e, embora no 1º tópico não pareça haver relação com esportes (*sport*), por eliminação, podemos considerar se tratar desse tópico. Esse detalhe que ocorre no 1º tópico é devido ao fato de que sendo o 1º tópico a ser definido, ele pode conter uma mistura dos outros tópicos, uma vez que na ordem de criação eles ainda não foram definidos e também porque o conjunto de dados não é tão grande a ponto de haver uma quantidade enorme de palavras para a formação de vetores mais densos no espaço. Entretanto, o algoritmo continua funcionando, sem grandes fatores prejudiciais.

Comparando com a classificação real já presente na base de dados, temos um resultado aproximidamente similar, como segue nas plotagens abaixo



Os erros aparentes eram esperados pois há textos que mesmo tendo "business" como o tema central, podem incluir termos de política ou mesmo tecnologia e, dependendo da frequência desses termos, o algoritmo pode não ser 100% eficaz. Mas, já é uma boa aproximação, levando em conta o tamanho da base de textos.

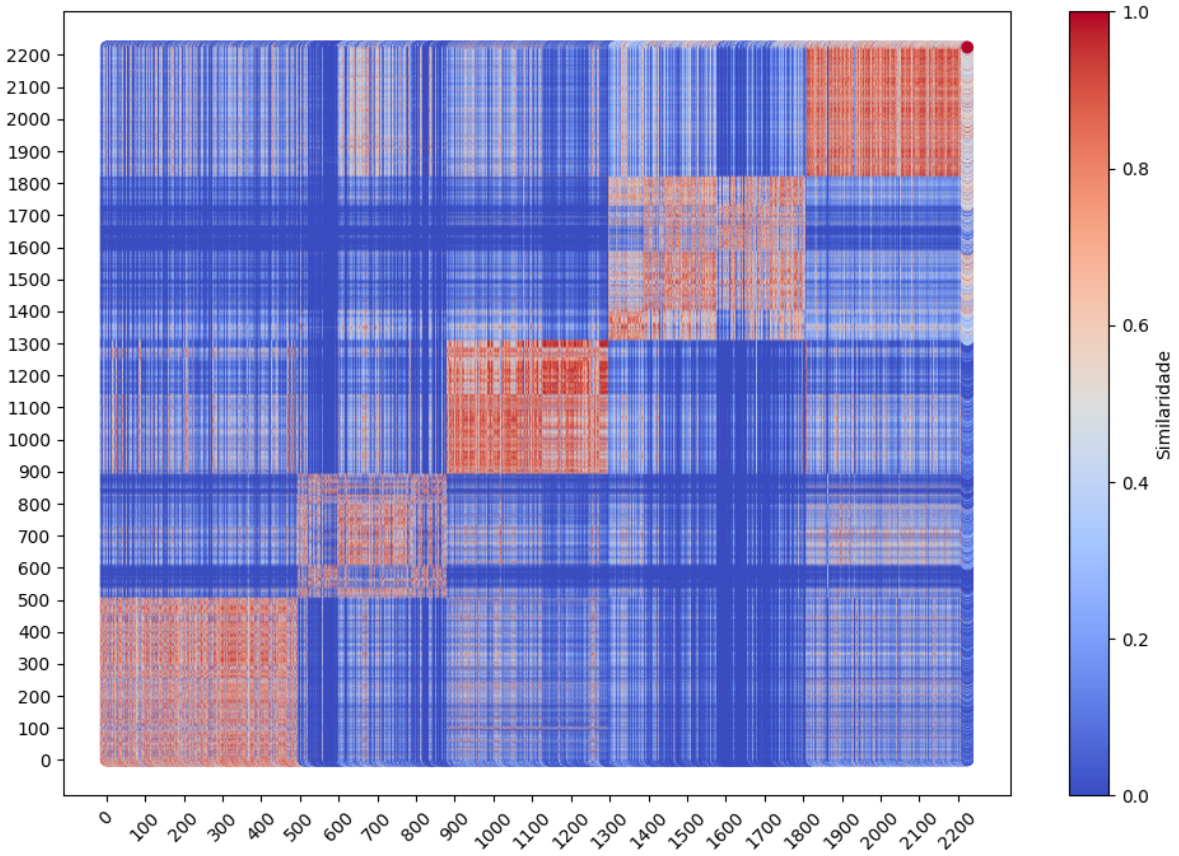
5.4 Medindo a Similaridade entre os Textos

Após reduzir a dimensão dos vetores nas nossas bases de dados, aplicamos o método de similaridade do cosseno em cada par de textos usando os vetores obtidos pelo TF-IDF. Representamos a similaridade entre eles em uma tabela. Os resultados são em uma escala de 0 a 1, de modo que 1 representa similaridade máxima.

	0	1	2	3	4	5	6	7	8	...	2216	2217	2218	2219	2220	2221	2222	2223	2224
0	1.0	0.596658	0.759898	0.819612	0.877666	0.333124	0.467438	0.546286	0.942529	...	0.304267	0.220767	0.248452	0.104843	0.485914	0.371503	0.379158	0.333666	0.063161
1	0.596658	1.0	0.779989	0.925211	0.589657	0.800596	0.948483	0.927015	0.605443	...	0.056249	0.023803	0.028845	0.00779	0.103956	0.067542	0.109276	0.106899	0.005378
2	0.759898	0.779989	1.0	0.849601	0.891823	0.408128	0.634868	0.880091	0.857776	...	0.235787	0.117989	0.13138	0.05145	0.326826	0.249202	0.383432	0.386811	0.037739
3	0.819612	0.925211	0.849601	1.0	0.765048	0.668852	0.827767	0.840343	0.79213	...	0.119285	0.063251	0.075286	0.024976	0.210484	0.146134	0.18843	0.175989	0.016593
4	0.877666	0.589657	0.891823	0.765048	1.0	0.264807	0.434553	0.647115	0.955388	...	0.398632	0.253463	0.282697	0.135878	0.534748	0.42587	0.542773	0.50849	0.106759
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2220	0.485914	0.103956	0.326826	0.210484	0.534748	0.027109	0.062323	0.12964	0.506927	...	0.927822	0.847173	0.870077	0.627042	1.0	0.97644	0.818986	0.754596	0.416475
2221	0.371503	0.067542	0.249202	0.146134	0.42587	0.01579	0.039637	0.089791	0.389058	...	0.966794	0.890285	0.906306	0.715952	0.97644	1.0	0.7911	0.745896	0.480251
2222	0.379158	0.109276	0.383432	0.18843	0.542773	0.021487	0.059642	0.167033	0.493743	...	0.870244	0.678185	0.666518	0.455037	0.818986	0.7911	1.0	0.97507	0.347653
2223	0.333666	0.106899	0.386811	0.175989	0.50849	0.021149	0.060696	0.17447	0.445354	...	0.839684	0.595476	0.582271	0.402782	0.754596	0.745896	0.97507	1.0	0.309189
2224	0.063161	0.005378	0.037739	0.016593	0.106759	0.000582	0.002242	0.009039	0.073738	...	0.535415	0.592419	0.632213	0.840162	0.416475	0.480251	0.347653	0.309189	1.0

2225 rows × 2225 columns

Ao analisarmos a similaridade de um texto consigo mesmo, observamos que o resultado foi de 1, indicando uma correspondência perfeita, o que era esperado. Os primeiros textos, por exemplo, abordam temáticas relacionadas à *business*, enquanto os últimos são voltados para assuntos relacionados a *tech*. Vê-se, então, que os resultados mostram eficacia, pois os valores obtidos para textos da mesma categoria são significativamente mais próximos entre si do que aqueles de categorias distintas. É relevante observar que alguns textos de categorias diferentes exibem similaridade inferior a 0.1, um padrão que não se verifica nos textos da mesma categoria. Esse fenômeno ressalta a eficiência do método na diferenciação entre tópicos específicos.



Posteriormente, visualizamos de maneira mais abrangente os resultados por meio de um gráfico de dispersão que se assemelha a uma matriz de confusão, conforme a imagem acima. A presença de quadrados com valores mais altos (cor mais avermelhada) mostra que as medições funcionaram, pois nossos textos estão agrupados com índices próximos, assim se formam esses quadrados nas diagonais, eles mostram que a similaridade do cosseno fornece valores mais altos para textos com mesmo tema.

6 Considerações Finais

Os resultados da classificação mostraram uma boa correspondência com as categorias reais dos textos, indicando que a abordagem é eficaz na identificação de tópicos em textos não categorizados. A similaridade do cosseno demonstrou ser uma métrica útil para avaliar a proximidade entre textos, destacando a eficiência do método proposto. Além disso, a Decomposição em Valores Singulares, se mostrou também ser um método muito eficiente para tratar (aproximadamente) os vetores que representam os textos para assim realizar as devidas comparações e agrupamentos.

No entanto, é importante notar que alguns textos podem abordar múltiplos tópicos, levando a pequenos erros de classificação. Além disso, o tamanho da base de dados pode influenciar a eficácia do método, especialmente em temas que possuem vocabulários mais limitados. Vale ressaltar que existem ainda outras técnicas (também com cunho em aspectos de Álgebra Linear) que tem um caráter mais especial quanto a quantidade de espaços latentes, distribuição de tópicos ou otimização, como o LDA (Latent Dirichlet Allocation) ou o NMF (Non-negative Matrix Factorization).

Em conclusão, a aplicação de técnicas de PLN, combinadas com métodos de aprendizado de máquina e técnicas de Álgebra Linear, mostrou-se promissora para a classificação de textos em temas específicos, mesmo sem categorias predefinidas. O aprimoramento contínuo dessas técnicas pode levar a avanços significativos na compreensão e organização de grandes volumes de informações textuais.

7 Referências

[1] Link para a base de dados: https://www.kaggle.com/datasets/shivamkushwaha/bbc-full-text-document-classification

[2] Course of Natural Language Processing. INTEL. Disponível em: https://www.intel.com/content/www/us/en/developer/topic-technology/artificial-intelligence/training/course-natural-language-processing.html

[3] Pré-Processamento de Textos. Linhares T.; Lima M. Disponível em: https://www.insightlab.ufc.br/pln-processamento-de-linguagem-natural-para-iniciantes/

[4] TF-IDF. Vaz. A. L. Disponível em: https://medium.com/data-hackers/tf-idf-algoritmo-de-recomendao-6c3cbd55e439

[5] Redução da dimensão de um conjunto de variáveis. Godinho E. R.; Coque J. A. R.; Huysmans G. G.; Brondino N. C. M. Disponível em: https://www.fc.unesp.br/Home/Departamentos/Matematica/revistacqd2228/v10a17-reducao-da-dimensao-de-um-conjunto-de-variaveis.pdf

[6] Entendendo o LSA, PCA e SVD. Santos V. Disponível em: https://www.computersciencemaster.com.br/entendendo-o-lsa-pca-e-svd/

[7] Aulas de **Autovatores** e **Autovelores** do Yuri. ECLASS. Disponível em: https://eclass.fgv.br/